

Laporan Praktikum Kontrol Cerdas Week 5

Nama : Muhammad Arif Ardiansyah
NIM : 224308090
Kelas : TKA 7D
Akun Github (Tautan) : <https://github.com/muhammadarifardiansyah19>

1. Judul Laporan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

- Memahami konsep *Deep Reinforcement Learning* (DRL) dalam kontrol sistem kompleks.
- Mengimplementasikan *Deep Q-Network* (DQN) untuk kontrol otomatis.
- Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Reinforcement Learning adalah sejenis metode pembelajaran mesin yang dilakukan oleh agen untuk mempelajari dan meningkatkan kebijakan melalui uji coba dan untuk memperoleh akumulasi hadiah dalam jangka panjang maksimum pada suatu tugas tertentu. Program akan memberi tahu agen tindakan mana yang harus dipilih disetiap keadaan lingkungan untuk memperoleh akumulasi hadiah yang lebih baik. sistem pembelajaran tidak mendapat informasi tentang tindakan yang direkomendasikan, melainkan harus menemukan sendiri tindakan mana yang menghasilkan hadiah paling banyak dengan mencoba semuanya (Baradja & Tjendrowasono, 2024). Dengan kata lain bahwa agen belajar mengambil keputusan melalui interaksi dengan lingkungan. Agen memperoleh reward atau penalty sebagai umpan balik dari tindakannya, sehingga ia dapat mengoptimalkan strategi untuk mencapai tujuan tertentu.

DQN adalah algoritma RL yang menggabungkan *algoritma Q-Learning* dengan *Deep Neural Network* (Putra et al., 2024). sehingga

memungkinkan agen untuk belajar dari pengalaman dan membuat keputusan dalam lingkungan yang rumit. Algoritma ini sangat berguna untuk menangani masalah dengan ruang keadaan yang besar. DQN bekerja dengan cara memanfaatkan jaringan saraf untuk memperkirakan nilai Q, yang merupakan nilai dari setiap aksi yang mungkin diambil dalam suatu keadaan tertentu. Dengan menggunakan pemutaran ulang pengalaman, DQN menyimpan pengalaman masa lalu dalam memori dan mengambil sampel acak dari pengalaman tersebut untuk memperbarui model, sehingga meningkatkan stabilitas dan efisiensi pembelajaran.

4. Analisis dan Diskusi

- Analisis

Pada praktikum melakukan Implementasi Agen DQN dengan menggunakan *environment* CartPole dimana performa agen dalam mengontrol *environment* CartPole yaitu Agen mampu mengendalikan CartPole mempertahankan keseimbangan dimana semakin besar episode training yang diberikan maka agent akan semakin lama bertahan. Pada cartpole pemberian reward dilakukan setiap langkah yang berhasil menjaga tiang tetap tegak akan diberi reward sebesar +1, sedangkan episode berakhir jika tiang jatuh atau kereta keluar batas. Jumlah maksimal langkah dalam satu episode sebesar 500 langkah dimana jika sudah mencapai 500 langkah maka episode akan berhenti walaupun tiang dalam kondisi masih tegak.

- Diskusi

kelebihan DQN dibandingkan metode Q-Learning klasik adalah Bisa menangani state space yang besar atau kontinu karena menggunakan neural network, lebih cocok untuk masalah kompleks (misalnya game atau robotika), memiliki mekanisme experience replay dan target network yang membuat pembelajaran lebih stabil. Sedangkan untuk kelemahan dari DQN dibandingkan metode Q-Learning klasik adalah membutuhkan komputasi yang tinggi (sering perlu GPU), Hyperparameter lebih banyak dan sulit ditentukan, Implementasi lebih rumit dibanding Q-Learning klasik.

Cara mengadaptasi DQN pada kontrol sistem dinamis seperti drone atau robot industri, pertama-tama sistem harus direpresentasikan sebagai lingkungan RL dengan mendefinisikan state (misal posisi, kecepatan, sensor), action (kontrol motor atau thrust), dan reward (misal menjaga stabilitas atau mencapai target). Karena DQN asli cocok untuk aksi diskrit, aksi kontinu biasanya perlu didiskritisasi atau menggunakan algoritma lain yang mendukung aksi kontinu. Neural network DQN dipakai untuk memperkirakan Q-value setiap aksi berdasarkan state, sementara replay buffer dan target network digunakan untuk stabilisasi pembelajaran. Selama pelatihan, agen memilih aksi berdasarkan state saat ini, menerima reward, dan memperbarui jaringan secara batch. Latihan sebaiknya dilakukan di simulator terlebih dahulu agar aman sebelum diterapkan ke sistem nyata, dengan reward yang dirancang agar mendorong perilaku stabil dan aman.

5. Assignment

Pada penugasaan dilakukan modifikasi program DQN dimana modifikasi dilakukan untuk kasus lain salah satunya pengendalian lengan robot dimana menggunakan Environment pendulum-v1. Environment Pendulum-v1 digunakan karena memiliki karakteristik fisik dan dinamika yang mirip dengan sistem lengan robot berengsel tunggal (single-link arm). Tujuan utama dari environment ini adalah menjaga batang (lengan) agar tetap tegak seimbang pada posisi vertikal, dengan cara memberikan gaya torsi (torque) pada porosnya.

Pada pendulum-v1 sistem pemberian reward berbeda dengan cartpole-v1 pada cartpole-v1 reward dilakukan setiap langkah yang berhasil menjaga tiang tetap tegak akan diberi reward sebesar +1 sedangkan pada pendulum-v1 reward dihitung menggunakan rumus negatif dari kombinasi deviasi sudut, kecepatan sudut, dan besar torsi, yaitu $r = -(\theta^2 + 0.1 \cdot \dot{\theta}^2 + 0.001 \cdot \tau^2)$. Artinya, semakin besar kemiringan, kecepatan putaran, atau gaya yang digunakan, maka reward semakin kecil (lebih negatif). Kondisi terbaik dengan reward maksimum (mendekati 0) dicapai saat batang tegak lurus, diam, dan tidak memerlukan torsi tambahan.


Performa DQN dan metode kontrol klasik seperti PID atau Fuzzy Logic berbeda berdasarkan prinsip kerja dan kemampuan adaptasinya. PID dan Fuzzy Logic bekerja berdasarkan model atau aturan yang sudah ditentukan, sehingga stabil dan cepat pada sistem linier atau semi-linier, tetapi sulit beradaptasi jika kondisi sistem berubah. Sebaliknya, DQN bersifat model-free dan belajar dari interaksi dengan lingkungan, memungkinkan mengatasi sistem nonlinear dan kompleks serta beradaptasi secara otomatis, namun membutuhkan waktu pelatihan lama dan sumber daya komputasi lebih besar. Dengan kata lain, PID/Fuzzy unggul dalam kesederhanaan dan stabilitas, sedangkan DQN unggul dalam fleksibilitas dan kemampuan menangani sistem yang sulit dimodelkan secara matematis.


6. Data dan Output Hasil Pengamatan

- Hasil training dari cartpole dan pendulum dengan 1000 episode

	Cartpolev1	Pendulum-v1
Episode awal	<pre> 9 Episode 7/1000, Score: 16, Epsilon: 0.97 10 Episode 8/1000, Score: 12, Epsilon: 0.97 11 Episode 9/1000, Score: 21, Epsilon: 0.96 12 Episode 10/1000, Score: 23, Epsilon: 0.96 13 Episode 11/1000, Score: 17, Epsilon: 0.95 14 Episode 12/1000, Score: 37, Epsilon: 0.95 15 Episode 13/1000, Score: 11, Epsilon: 0.94 16 Episode 14/1000, Score: 107, Epsilon: 0.94 </pre>	<pre> Episode 1/1000 Score: 200 Reward: -103.07 Epsilon: 1.00 WARNING:tensorflow:From C:\Users\ACER\AppData\Local\Programs\Python\Py 492: The name tf.nn.RaggedTensorValue is deprecated. Please use tf Episode 2/1000 Score: 200 Reward: -89.29 Epsilon: 0.99 Episode 3/1000 Score: 200 Reward: -124.81 Epsilon: 0.99 Episode 4/1000 Score: 200 Reward: -127.30 Epsilon: 0.99 Episode 5/1000 Score: 200 Reward: -166.29 Epsilon: 0.98 </pre>
Episode akhir	<pre> 998 Episode 988/1000, Score: 290, Epsilon: 0.01 991 Episode 989/1000, Score: 244, Epsilon: 0.01 992 Episode 990/1000, Score: 344, Epsilon: 0.01 993 Episode 991/1000, Score: 14, Epsilon: 0.01 994 Episode 992/1000, Score: 18, Epsilon: 0.01 995 Episode 993/1000, Score: 18, Epsilon: 0.01 996 Episode 994/1000, Score: 16, Epsilon: 0.01 997 Episode 995/1000, Score: 17, Epsilon: 0.01 998 Episode 996/1000, Score: 17, Epsilon: 0.01 999 Episode 997/1000, Score: 93, Epsilon: 0.01 1000 Episode 998/1000, Score: 19, Epsilon: 0.01 1001 Episode 999/1000, Score: 113, Epsilon: 0.01 1002 Episode 1000/1000, Score: 174, Epsilon: 0.01 1003 Training selesai! Model disimpan sebagai dqn_cartpole.keras </pre>	<pre> Episode 992/1000 Score: 200 Reward: -12.62 Epsilon: 0.01 Episode 993/1000 Score: 200 Reward: -12.08 Epsilon: 0.01 Episode 994/1000 Score: 200 Reward: -23.98 Epsilon: 0.01 Episode 995/1000 Score: 200 Reward: -40.07 Epsilon: 0.01 Episode 996/1000 Score: 200 Reward: -12.31 Epsilon: 0.01 Episode 997/1000 Score: 200 Reward: -24.88 Epsilon: 0.01 Episode 998/1000 Score: 200 Reward: -12.36 Epsilon: 0.01 Episode 999/1000 Score: 200 Reward: -23.32 Epsilon: 0.01 Episode 1000/1000 Score: 200 Reward: -0.31 Epsilon: 0.01 Training selesai! Model disimpan sebagai dqn_robot_arm.keras </pre>


Grafik hasil training





Pada grafik dapat dilihat bahwa nilai reward pada CartPole-v1 cenderung naik mendekati 500. Kemudian pada Pendulum-v1, nilai reward yang dihasilkan meningkat mendekati 0.

- Hasil testing dari cartpole dan pendulum dengan 100 episode



Hasil testing dengan 100 episode didapatkan hasil dimana rata rata nilai pada cartpole sekitar 96,97 dan untuk nilai rata – rata pada pendulum sekitar -283,88.

7. Kesimpulan

Berdasarkan praktikum dan analisis yang telah dilakukan dapat disimpulkan bahwa:

1. algoritma *Deep Q-Network* (DQN) mampu belajar secara efektif dalam mengendalikan sistem dinamis tanpa memerlukan model matematis lingkungan.
2. Pada *environment* CartPole-v1, nilai reward meningkat mendekati 500, menandakan bahwa agen berhasil menjaga keseimbangan tiang dengan stabil dan pada *environment* Pendulum-v1, reward meningkat mendekati 0, menunjukkan bahwa agen mampu meminimalkan deviasi sudut dan torsi yang digunakan sehingga sistem menjadi lebih seimbang.
3. Implementasi DQN terbukti efektif untuk kontrol sistem kompleks dan nonlinear, meskipun membutuhkan waktu pelatihan dan sumber daya komputasi yang lebih besar dibandingkan metode kontrol konvensional seperti PID atau Fuzzy Logic.

8. Saran

Pada percobaan ini disarankan untuk meningkatkan jumlah episode pelatihan agar hasil pembelajaran lebih stabil dan akurat. Selain itu, pengaturan parameter seperti learning rate, gamma, dan epsilon decay dapat dioptimalkan agar proses konvergensi lebih cepat.

9. Daftar Pustaka

- Baradja, A., & Tjendrowasono, T. I. (2024). Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>
- Putra, R. A., Syahbana, Y. A., & Ananda. (2024). Implementasi Algoritma Deep Q-Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. *The Indonesian Journal of Computer Science*, 13(5). <https://doi.org/10.33022/ijcs.v13i5.4372>

